

Savoir quand on ne sait pas : quantification de l'incertitude pour la classification d'images médicales

Comparaison de MC Dropout, des Deep Ensembles et de l'Evidential Deep Learning

Francois Lachance Awounang-Ngounou

Résumé

Un réseau de neurones classique produit toujours une réponse, y compris lorsqu'il devrait s'abstenir. Sur une radiographie thoracique ambiguë, bruitée ou simplement issue d'un appareil jamais rencontré à l'entraînement, la fonction softmax peut annoncer une probabilité de 0,92 pour la classe pneumonie tout en se trompant. Le modèle est alors confiant et faux, et rien dans sa sortie ne permet au clinicien de distinguer ce cas d'un cas d'école. Ce travail implémente et compare cinq configurations destinées à produire une estimation d'incertitude exploitable pour un classifieur d'images médicales, puis mesure si cette incertitude mérite d'être crue. Ces configurations sont la référence softmax, le temperature scaling, le Monte Carlo Dropout, les Deep Ensembles et l'Evidential Deep Learning. L'évaluation repose sur la calibration (Expected Calibration Error, score de Brier, log vraisemblance négative), sur la capacité à ordonner les erreurs (AUROC de détection d'erreur, test de Mann et Whitney), sur la prédiction sélective (courbes risque contre couverture, AURC) et sur le comportement face à sept dégradations d'acquisition à cinq niveaux de sévérité. Le protocole complet est répété sur trois graines. Sur PneumoniaMNIST, l'Evidential Deep Learning atteint la meilleure calibration (ECE de $0,046 \pm 0,012$ contre $0,095 \pm 0,022$ pour la référence) pour le coût d'un seul *forward pass*, tandis que les Deep Ensembles dominent la qualité de décision (exactitude de $0,873 \pm 0,002$, AURC de $0,039 \pm 0,001$) et divisent par dix la variabilité entre graines. Hors distribution, le classement s'inverse : le MC Dropout devient la configuration la plus robuste, alors que l'Evidential Deep Learning s'effondre sous la proportion de la classe majoritaire. La répétition conduit en outre à écarter toute comparaison fondée sur l'AUROC de détection d'erreur, dont les écarts entre méthodes se révèlent inférieurs à la variance d'initialisation. Le résultat principal est qu'aucune configuration ne domine uniformément, et qu'une bonne calibration en distribution ne garantit en rien la robustesse hors distribution.

Mots clés : quantification d'incertitude, calibration, imagerie médicale, apprentissage profond bayésien, distribution de Dirichlet, prédiction sélective.

1 Introduction

1.1 Le problème

Les performances des réseaux de neurones en imagerie médicale sont aujourd'hui comparables à celles d'experts humains sur de nombreuses tâches de classification. Cette exactitude moyenne masque cependant une propriété qui limite fortement leur usage clinique : le modèle ne dispose d'aucun moyen d'exprimer son ignorance.

La cause est structurelle. La couche softmax normalise ses sorties de sorte que leur somme vaille un, quelle que soit l'entrée. Présentée à une image totalement étrangère au domaine d'entraînement, l'architecture doit répartir l'intégralité de la masse de probabilité entre les classes qu'elle connaît. Elle ne dispose d'aucune case où inscrire la réponse « aucune de ces classes, je n'ai jamais rien vu de tel ». Elle peut exprimer une ambiguïté entre classes connues, par exemple un vecteur $(0,5; 0,5)$, mais jamais une absence de connaissance.

En pratique, la conséquence est qu’un modèle déployé sur un site hospitalier différent de celui ayant fourni les données d’entraînement dégrade son exactitude sans que rien ne le signale. Le radiologue reçoit des prédictions accompagnées de scores de confiance élevés, sans indication sur celles qu’il conviendrait de vérifier. C’est la différence entre un outil d’aide à la décision utilisable et un outil dangereux.

1.2 Objectif et contributions

L’objectif de ce travail n’est pas d’améliorer l’exactitude d’un classifieur, mais de doter ce classifieur d’une mesure d’incertitude, puis de vérifier expérimentalement que cette mesure est fiable. Les contributions sont les suivantes.

- Une implémentation unifiée de quatre stratégies de quantification d’incertitude derrière une interface commune, de sorte que la comparaison isole la méthode et non l’architecture ou le protocole d’entraînement.
- Une chaîne d’évaluation complète mesurant la calibration, la détection d’erreur, la prédiction sélective, le coût de calcul et la robustesse à sept dégradations d’acquisition réalistes.
- Une validation croisée sur deux jeux de données, l’un réel (PneumoniaMNIST), l’autre synthétique dont le taux d’erreur de Bayes est connu par construction, ce qui permet de séparer ce qui relève de la méthode de ce qui relève des données.
- Une suite de 49 tests automatisés validant les identités mathématiques du code, en particulier les formes closes de l’incertitude dirichletienne comparées à une estimation de Monte Carlo.
- Une méthodologie de contrôle qui a permis de détecter, en cours d’expérience, un artefact d’implémentation invalidant silencieusement une ligne de résultats. Cet épisode est documenté en section 6.3 car il illustre l’importance des contrôles de cohérence.

2 Fondements théoriques

2.1 Les trois natures de l’incertitude

La distinction entre incertitude réductible et irréductible, formalisée en vision par ordinateur par Kendall et Gal [6], structure l’ensemble de ce travail. Toute méthode étudiée ici produit soit un ensemble de S vecteurs de probabilité par image, soit une distribution de Dirichlet. Ces deux formes sont réduites aux mêmes trois quantités afin que la comparaison soit menée à armes égales.

L’incertitude *totale* est l’entropie de la prédiction moyenne :

$$\mathcal{H}_{\text{tot}} = H[\mathbb{E}_{\theta} p_{\theta}(y \mid x)]. \quad (1)$$

L’incertitude *aléatoire* est l’espérance de l’entropie :

$$\mathcal{H}_{\text{ale}} = \mathbb{E}_{\theta} H[p_{\theta}(y \mid x)]. \quad (2)$$

Elle mesure le bruit irréductible contenu dans la donnée. Une lésion réellement ambiguë reste ambiguë quelle que soit la quantité de données supplémentaires collectées.

L’incertitude *épistémique* est la différence des deux, c’est à dire l’information mutuelle entre la prédiction et les paramètres :

$$\mathcal{H}_{\text{epi}} = I[y; \theta] = \mathcal{H}_{\text{tot}} - \mathcal{H}_{\text{ale}} \geq 0. \quad (3)$$

Elle mesure l’ignorance du modèle, c’est à dire le désaccord entre les modèles compatibles avec les données observées. Contrairement à la précédente, elle est réductible : davantage de données de ce type la fait disparaître.

Cette distinction possède une traduction clinique directe, résumée dans le tableau 1.

TABLE 1 – Traduction clinique de la décomposition de l’incertitude. Les deux situations produisent une incertitude totale élevée mais appellent des conduites opposées.

Type tude	d’incerti-	Causes	Actions appropriées
Aléatoire élevée		L’information n’est pas présente dans l’image	Changer de modalité d’examen
Épistémique élevée		Le cas ne ressemble pas aux données d’entraînement	Ne pas se fier au modèle, lecture humaine

Toutes les entropies employées dans ce travail sont normalisées par $\log K$, où K désigne le nombre de classes, de sorte que les valeurs restent dans l’intervalle $[0, 1]$ et comparables entre jeux de données.

2.2 Référence softmax et temperature scaling

La référence consiste à interpréter la probabilité softmax maximale comme un score de confiance. Avec un unique réseau déterministe, la distribution sur θ est un Dirac, les deux premiers termes coïncident et l’incertitude épistémique vaut exactement zéro. Ce n’est pas une faiblesse de qualité mais une impossibilité structurelle.

Le temperature scaling [4] corrige a posteriori la sur confiance en divisant les logits par un scalaire T ajusté par minimisation de la log vraisemblance négative sur l’ensemble de validation :

$$\hat{p}_k = \frac{\exp(z_k/T)}{\sum_j \exp(z_j/T)}. \quad (4)$$

La transformation étant strictement monotone, elle ne modifie ni la classe prédite ni l’ordre induit par l’incertitude. Elle est incluse ici comme concurrent bon marché, car toute comparaison honnête doit vérifier qu’un ensemble de cinq modèles bat réellement un scalaire ajusté en deux secondes.

2.3 Monte Carlo Dropout

Le dropout est habituellement un régulariseur réservé à l’entraînement. Gal et Ghahramani [1] ont montré que le maintenir actif à l’inférence revient à échantillonner une postérieure approchée sur les poids. Chaque *forward pass*, c’est à dire chaque traversée complète du réseau par une image, utilise un sous réseau différent. Les S *forward pass* appliqués à la même image produisent donc S prédictions dont la dispersion estime l’incertitude épistémique.

Deux détails d’implémentation séparent un MC Dropout fonctionnel d’un MC Dropout décoratif. Premièrement, le dropout doit être inséré après chaque bloc convolutif et non uniquement avant le classifieur, faute de quoi la perturbation reste marginale et l’incertitude épistémique est fortement sous estimée. Deuxièmement, les couches de normalisation doivent rester déterministes. L’usage de la GroupNorm plutôt que de la BatchNorm résout ce point de manière définitive : avec la BatchNorm, il faut réactiver le dropout seul, sans quoi les statistiques de lot fuient entre les échantillons et l’incertitude devient fonction de la composition du lot.

2.4 Deep Ensembles

La méthode consiste à entraîner M réseaux indépendants sur les mêmes données, puis à moyenner leurs prédictions [2]. La diversité provient de trois sources : l’initialisation aléatoire des poids, l’ordre de présentation des exemples et les tirages d’augmentation. Aucun rééchantillonnage des données n’est employé, les auteurs ayant montré que les redémarrages aléatoires suffisent et que le bagging dégrade généralement chaque membre en réduisant son ensemble d’entraînement.

Là où les membres s'accordent, la prédiction est sûre. Là où ils divergent, l'entrée se situe hors de la région contrainte par les données, et le canal épistémique s'active. Cette méthode est généralement considérée comme la référence pratique, au prix de M entraînements complets.

2.5 Evidential Deep Learning

Plutôt qu'un vecteur de probabilités, le réseau produit une quantité d'*évidence* non négative $e_k = \text{softplus}(z_k)$, qui paramètre une distribution de Dirichlet sur le simplexe [3] :

$$\alpha_k = e_k + 1, \quad S = \sum_{k=1}^K \alpha_k, \quad \hat{p}_k = \frac{\alpha_k}{S}, \quad u = \frac{K}{S}. \quad (5)$$

Le modèle prédit donc une distribution sur les vecteurs de probabilité, et non un point du simplexe. La quantité u , appelée vacuité, tend vers un lorsque le réseau n'a recueilli aucune évidence. Elle constitue l'énoncé littéral de l'ignorance, que le softmax ne peut pas représenter. L'entropie attendue sous la Dirichlet admet une forme close faisant intervenir la fonction digamma :

$$\mathbb{E}_{p \sim \text{Dir}(\alpha)} H[p] = - \sum_{k=1}^K \frac{\alpha_k}{S} [\psi(\alpha_k + 1) - \psi(S + 1)]. \quad (6)$$

L'entraînement minimise le risque bayésien du score de Brier sous la Dirichlet, augmenté d'un terme de divergence de Kullback et Leibler qui ramène vers l'uniforme l'évidence attribuée aux classes erronées :

$$\mathcal{L} = \underbrace{\sum_{k=1}^K \left[(y_k - \hat{p}_k)^2 + \frac{\hat{p}_k(1 - \hat{p}_k)}{S + 1} \right]}_{\text{ajustement et variance}} + \lambda_t \underbrace{\text{KL}(\text{Dir}(\tilde{\alpha}) \parallel \text{Dir}(\mathbf{1}))}_{\text{pénalisation de l'évidence trompeuse}}, \quad (7)$$

où $\tilde{\alpha} = y + (1 - y) \odot \alpha$ retire l'évidence de la classe correcte avant pénalisation. Le poids λ_t croît linéairement de zéro jusqu'à un sur les dix premières époques. Ce calendrier progressif constitue la principale difficulté pratique de la méthode : une montée trop rapide fait s'effondrer toute l'évidence vers zéro, et le modèle devient uniformément, donc inutilement, incertain.

L'intérêt majeur de cette approche est qu'elle fournit une incertitude épistémique en un seul *forward pass*, sans échantillonnage ni entraînements multiples.

3 Protocole d'évaluation

3.1 Calibration

Un modèle est dit calibré si, parmi les cas qu'il annonce avec une confiance de 0,8, il a effectivement raison dans huit cas sur dix. L'exactitude seule ne détecte pas la mauvaise calibration : un modèle exact à 95 % peut annoncer 99,9 % de confiance sur chaque cas.

L'Expected Calibration Error découpe les prédictions en M intervalles de confiance de largeur égale et mesure l'écart moyen pondéré entre exactitude et confiance :

$$\text{ECE} = \sum_{m=1}^M \frac{|B_m|}{n} |\text{acc}(B_m) - \text{conf}(B_m)|. \quad (8)$$

Trois variantes complémentaires sont également calculées. L'ECE adaptatif emploie des intervalles de masse égale, préférable lorsque les confiances s'accumulent près de un et laissent les intervalles de largeur égale presque vides. Le MCE retient le pire intervalle, chiffre pertinent pour une revue de sécurité. L'ECE par classe évite qu'une classe rare mais critique soit mal calibrée sans que la métrique globale le révèle. Le score de Brier et la log vraisemblance négative complètent l'ensemble : ce sont des règles de score propres, pénalisant conjointement l'inexactitude et la mauvaise calibration.

3.2 Détection d’erreur et prédiction sélective

La calibration répond à la question de la justesse moyenne des confiances annoncées. Elle ne dit rien sur l’identification des cas individuellement erronés. Trois mesures complémentaires sont donc employées.

L’AUROC de détection d’erreur mesure la capacité de l’incertitude à ordonner les erreurs au dessus des prédictions correctes. Une valeur de 0,5 signifie que l’incertitude ne porte aucune information sur la correction.

Le test de Mann et Whitney fournit la version statistique de la même affirmation, avec une valeur p associée à l’hypothèse selon laquelle les cas mal classés portent une incertitude supérieure.

La courbe risque contre couverture correspond à l’usage réel envisagé. Les cas sont triés par incertitude croissante, la fraction la plus incertaine est déléguée à un lecteur humain, et le taux d’erreur est mesuré sur le reste. L’aire sous cette courbe, notée AURC, résume la qualité du tri. Cette métrique traduit directement l’argument de déploiement : à quel taux d’erreur peut on descendre en acceptant de déléguer une fraction donnée des cas.

3.3 Robustesse au décalage de distribution

L’exactitude sur un jeu de test propre masque le comportement le plus important, comme l’a montré l’étude à grande échelle d’Ovadia et ses coauteurs [5]. Chaque méthode est ici évaluée sous sept dégradations d’acquisition réalistes, à cinq niveaux de sévérité : bruit gaussien, bruit de Poisson simulant une acquisition à faible dose, flou de mouvement, perte de contraste, surexposition, occlusion et perte de résolution.

La signature recherchée est simple. L’exactitude doit chuter et l’incertitude doit croître conjointement. Une courbe d’incertitude plate pendant que l’exactitude s’effondre correspond exactement au mode de défaillance que ce travail cherche à détecter.

4 Protocole expérimental

4.1 Jeux de données

Le jeu principal est PneumoniaMNIST, issu de la collection MedMNIST v2 [7]. Il comprend 4708 radiographies thoraciques pédiatriques d’entraînement, 524 de validation et 624 de test, en niveaux de gris et en résolution 28×28 , réparties en deux classes, normale et pneumonie.

Une propriété de ce jeu s’est révélée déterminante pour l’interprétation. L’ensemble de validation est un sous ensemble aléatoire des mêmes patients que l’entraînement, alors que l’ensemble de test provient de patients distincts. Un décalage de distribution réel existe donc entre validation et test, avant même toute dégradation artificielle.

Un second jeu, synthétique, est employé comme contrôle. Des images de fond lisse contenant, pour la moitié d’entre elles, une lésion gaussienne sont générées procéduralement. Un quart des cas positifs reçoit une lésion de contraste délibérément très faible, ce qui installe par construction une incertitude aléatoire irréductible et fixe le plafond de Bayes autour de 0,87. Ce dispositif permet de vérifier que les méthodes détectent bien une ambiguïté dont on sait qu’elle existe.

4.2 Architecture et entraînement

Une architecture unique est partagée par toutes les méthodes afin que la comparaison isole la stratégie d’incertitude. Il s’agit d’un réseau convolutif de trois blocs, chacun composé de deux convolutions 3×3 , d’une GroupNorm, d’une activation ReLU, d’un sous échantillonnage et d’un dropout spatial de taux 0,3, suivi d’un agrégat global et d’une tête dense. Le modèle compte 303 650 paramètres, taille délibérément réduite afin que l’entraînement de cinq membres d’ensemble reste réalisable sur un processeur classique.

L’optimiseur est AdamW avec un pas initial de 10^{-3} , une décroissance cosinus sur 25 époques, une régularisation L_2 de 10^{-4} et un écrêtage du gradient à 5. L’augmentation se limite à une symétrie horizontale et à une translation de deux pixels au plus. Les Deep Ensembles comptent cinq membres entraînés avec les graines 1000 à 5000, et le MC Dropout emploie trente *forward passes*. La référence et le MC Dropout partagent exactement les mêmes poids, ce qui souligne que le MC Dropout est une procédure purement inférentielle applicable à un modèle déjà entraîné.

4.3 Reproductibilité

Chaque exécution enregistre ses hyperparamètres, ses points de contrôle, ses prédictions brutes et l’ensemble de ses métriques dans des fichiers exploitables par machine. Les générateurs aléatoires, y compris celui gouvernant l’augmentation, sont réinitialisés au début de chaque entraînement à partir de la graine du modèle, ce qui garantit qu’une même graine produit exactement le même réseau.

Une suite de 49 tests automatisés valide les propriétés mathématiques du code. Parmi les plus significatifs, un test vérifie que les formes closes de l’incertitude dirichletienne coïncident, à 0,01 près, avec une estimation obtenue par échantillonnage de vingt mille tirages. Un autre vérifie qu’une population synthétique parfaitement calibrée obtient bien un ECE proche de zéro. Un troisième vérifie que le temperature scaling retrouve un facteur d’échelle connu appliqué artificiellement à des logits. Un quatrième vérifie que l’incertitude épistémique vaut exactement zéro pour un modèle déterministe et devient maximale pour des membres d’ensemble en désaccord confiant.

5 Résultats

5.1 Protocole de répétition

L’ensemble du protocole a été exécuté trois fois, avec les graines 0, 1 et 2. Chaque exécution réentraîne intégralement les sept réseaux concernés, à savoir la référence partagée avec le MC Dropout, les cinq membres d’ensemble et le modèle évidentiel, puis recalcule toutes les métriques. Les valeurs rapportées ci après sont des moyennes assorties de l’écart type empirique calculé sur ces trois répétitions.

Cette précaution s’est révélée indispensable. Sur un jeu de test de 624 images, la variabilité induite par la seule initialisation aléatoire atteint deux points d’exactitude pour la référence, amplitude comparable à celle des écarts entre méthodes. Une conclusion tirée d’une exécution unique aurait donc confondu effet de méthode et bruit d’initialisation.

5.2 Performance et calibration en distribution

Le tableau 2 rassemble les résultats obtenus sur l’ensemble de test de PneumoniaMNIST.

TABLE 2 – Performance et calibration sur l’ensemble de test de PneumoniaMNIST (624 images), moyennes et écarts types sur trois graines. Les flèches indiquent le sens d’amélioration.

Méthode	Exactitude $\uparrow$	ECE $\downarrow$	AUROC $\uparrow$	AURC $\downarrow$	NLL $\downarrow$
Référence softmax	$0,852 \pm 0,020$	$0,095 \pm 0,022$	$0,799 \pm 0,017$	$0,050 \pm 0,008$	$0,462 \pm 0,049$
Temperature scaling	$0,852 \pm 0,020$	$0,101 \pm 0,023$	$0,799 \pm 0,017$	$0,050 \pm 0,008$	$0,491 \pm 0,055$
MC Dropout ($S = 30$)	$0,840 \pm 0,018$	$0,081 \pm 0,017$	$0,803 \pm 0,015$	$0,054 \pm 0,006$	$0,435 \pm 0,027$
Deep Ensemble ($M = 5$)	$0,873 \pm 0,002$	$0,066 \pm 0,006$	$0,808 \pm 0,004$	$0,039 \pm 0,001$	$0,379 \pm 0,010$
Evidential Deep Learning	$0,854 \pm 0,015$	$0,046 \pm 0,012$	$0,802 \pm 0,018$	$0,049 \pm 0,005$	$0,354 \pm 0,020$

Quatre observations se dégagent.

L'Evidential Deep Learning est le mieux calibré des cinq configurations, avec un ECE moyen de 0,046 contre 0,095 pour la référence, soit une réduction de 51 %. L'avantage est de surcroît systématique, la méthode devançant les Deep Ensembles sur chacune des trois graines prises séparément. Elle obtient également la meilleure log vraisemblance négative. Ces deux résultats sont acquis pour le coût d'un seul *forward pass*, identique à celui de la référence.

Les Deep Ensembles dominent la qualité de décision. Leur exactitude moyenne de 0,873 est la plus élevée, et leur AURC de 0,039 représente une réduction de 22 % par rapport à la référence, avantage lui aussi obtenu sur les trois graines.

La référence softmax est la configuration la plus mal calibrée, avec un ECE moyen de 0,095. Son diagramme de fiabilité, reproduit en figure 1, montre des barres systématiquement situées sous la diagonale dans la plage de confiance comprise entre 0,6 et 0,95, signature classique de la surconfiance.

Le MC Dropout améliore modestement la calibration de la référence, de 0,095 à 0,081, mais dégrade l'AURC, de 0,050 à 0,054, et cette dégradation s'observe également sur les trois graines. Rapporté à un coût d'inférence trente fois supérieur, le bilan en distribution est défavorable.




FIGURE 1 – Diagramme de fiabilité des cinq configurations. La diagonale correspond à la calibration parfaite. L'aire des marqueurs est proportionnelle au nombre d'échantillons contenus dans l'intervalle, afin que le lecteur puisse juger du poids de chaque point.

5.3 Ce que la variabilité entre graines invalide

La répétition du protocole conduit à écarter une conclusion que l'exécution initiale semblait autoriser.

Les moyennes d'AUROC de détection d'erreur s'échelonnent de 0,799 à 0,808 selon la méthode, soit un intervalle de 0,009, alors que l'écart type entre graines atteint 0,017 pour la référence et 0,018 pour l'Evidential Deep Learning. L'amplitude du bruit d'initialisation dépasse donc du double celle des écarts mesurés entre méthodes.

Le détail par graine confirme l'absence de classement stable. L'Evidential Deep Learning obtient 0,8080 sur la première graine, valeur qui le place au deuxième rang, puis 0,7811 sur la deuxième,

valeur qui le place au dernier rang, puis 0,8161 sur la troisième, valeur qui le place au premier rang. Aucune conclusion ne peut être tirée quant à la capacité relative des méthodes à ordonner leurs erreurs sur ce jeu de données.

Ce constat illustre une limite méthodologique répandue dans la littérature comparative. Sur des jeux de test de quelques centaines d’images, les écarts publiés entre méthodes de quantification d’incertitude sont fréquemment du même ordre que la variance d’initialisation, et une exécution unique ne permet pas de les distinguer.

5.4 La réduction de variance, bénéfice principal de l’ensembling

La répétition fait apparaître un résultat que l’exécution unique ne pouvait pas révéler, et qui constitue probablement l’argument le plus fort en faveur des Deep Ensembles.

TABLE 3 – Écarts types entre graines, exprimés en multiples de celui obtenu par les Deep Ensembles. Une valeur élevée signale une méthode dont le résultat dépend fortement du hasard de l’initialisation.

Méthode	Exactitude	ECE	AUROC	AURC
Référence softmax	10,0×	3,7×	4,3×	8,0×
Temperature scaling	10,0×	3,8×	4,3×	8,0×
MC Dropout	9,0×	2,8×	3,8×	6,0×
Evidential Deep Learning	7,5×	2,0×	4,5×	5,0×
Deep Ensemble	1,0×	1,0×	1,0×	1,0×

L’exactitude de la référence varie de 0,835 à 0,873 selon la graine, soit une amplitude de près de quatre points. Celle des Deep Ensembles varie de 0,872 à 0,875, amplitude dix fois moindre. Le même rapport se retrouve, à des degrés divers, sur les quatre métriques.

Ce comportement était prévisible sur le plan théorique et constitue même la justification de la méthode : moyennier M réseaux indépendants réduit la variance de l’estimateur d’un facteur voisin de M . Sa portée pratique mérite toutefois d’être soulignée. Pour un déploiement clinique, la reproductibilité peut importer davantage que la performance moyenne, car elle garantit que le modèle livré correspond effectivement à celui qui a été validé. Un réentraînement du modèle de référence, par exemple à l’occasion d’une mise à jour du jeu de données, peut faire varier son exactitude de quatre points sans qu’aucune modification n’ait été apportée au protocole.

Cette stabilité s’observe également sous décalage de distribution. À la sévérité maximale, l’incertitude moyenne des Deep Ensembles vaut $0,914 \pm 0,019$, alors que celle de la référence vaut $0,663 \pm 0,188$, écart type dix fois supérieur. Autrement dit, non seulement la référence signale moins bien la dégradation, mais l’intensité de son signal dépend fortement de son initialisation.

5.5 Échec du temperature scaling

Le facteur ajusté sur la validation vaut 0,939, 0,911 et 0,905 selon la graine, soit une moyenne de 0,918. Une valeur inférieure à un accentue les logits et augmente donc la confiance. Le résultat est un ECE dégradé sur les trois graines sans exception, passant en moyenne de 0,095 à 0,101, la log vraisemblance négative se dégradant également de 0,462 à 0,491.

L’explication tient à la structure du jeu de données. L’exactitude de validation se situe entre 0,947 et 0,958 selon la graine, alors que l’exactitude de test plafonne entre 0,835 et 0,873, soit environ dix points d’écart. Sur la validation, composée des mêmes patients que l’entraînement, le modèle est légèrement sous confiant, et l’optimiseur choisit donc d’accentuer ses logits. Sur le test, composé de patients distincts, le modèle est au contraire sur confiant, et la correction est appliquée dans le mauvais sens.

Le caractère systématique de cette défaillance, observé sur trois entraînements indépendants avec trois facteurs distincts mais tous inférieurs à un, exclut l’hypothèse d’un accident d’optimisation.

Le constat dépasse donc le cas particulier. Le temperature scaling suppose que validation et test partagent la même courbe de calibration. C’est précisément l’hypothèse qui tombe en situation clinique, où le décalage entre sites, appareils et populations est la règle plutôt que l’exception. Une méthode de calibration a posteriori ajustée sur des données internes ne se transporte pas hors de leur distribution.

5.6 Prédiction sélective

La figure 2 présente les courbes risque contre couverture. Elles traduisent l’usage envisagé : le taux d’erreur obtenu lorsque l’on accepte de déléguer à un lecteur humain une fraction des cas jugés les plus incertains.




FIGURE 2 – Courbes risque contre couverture sur l’ensemble de test. Une courbe basse indique un meilleur tri des cas difficiles. L’AURC correspondant figure en légende.

Les Deep Ensembles conservent un avantage sur toute la plage de couverture, et il s’agit du seul avantage en matière de tri qui résiste à la répétition sur trois graines. Toutes les méthodes obtiennent par ailleurs une valeur p inférieure à 10^{-15} au test de Mann et Whitney, ce qui confirme statistiquement que les images mal classées portent une incertitude significativement supérieure. L’incertitude produite n’est donc décorative pour aucune des méthodes évaluées.

5.7 Robustesse au décalage de distribution

Le tableau 4 rapporte l’évolution conjointe de l’exactitude et de l’incertitude moyenne sous bruit gaussien croissant, moyennée sur les trois graines.

TABLE 4 – Comportement sous bruit gaussien, moyennes sur trois graines. La sévérité zéro correspond aux données propres, la sévérité cinq à la dégradation maximale.

Méthode	Exactitude		Incertitude moyenne	
	sévérité 0	sévérité 5	sévérité 0	sévérité 5
Référence softmax	0,852	0,562	0,217	0,663
Temperature scaling	0,852	0,562	0,198	0,633
MC Dropout	0,840	0,628	0,275	0,765
Deep Ensemble	0,873	0,571	0,229	0,914
Evidential Deep Learning	0,854	0,408	0,401	0,598

Le classement s’inverse par rapport à la situation en distribution, et cette inversion est reproduite sur les trois graines.

Le Monte Carlo Dropout conserve la meilleure exactitude sous dégradation maximale, avec 0,628 contre 0,562 pour la référence. Deux mécanismes l’expliquent plausiblement : la moyenne sur trente *forward passes* stochastiques lisse le bruit ajouté, et le dropout agit comme une régularisation réduisant la sensibilité aux perturbations pixel à pixel.

Les Deep Ensembles produisent le signal d’alerte le plus net, leur incertitude atteignant 0,914 à la sévérité maximale, valeur proche de la saturation. Ce comportement est celui que l’on attend d’un système sûr : la perte d’exactitude s’accompagne d’une demande explicite de vérification humaine.

L’Evidential Deep Learning s’effondre. Son exactitude tombe à 0,408, soit en dessous de la proportion de la classe majoritaire dans l’ensemble de test, ce qui signifie qu’il fait moins bien qu’une stratégie consistant à prédire systématiquement la classe la plus fréquente. Son incertitude ne progresse que de 0,401 à 0,598, restant très loin du maximum atteignable, et son ECE atteint 0,380 sur la première graine, valeur la plus défavorable de toute l’étude. Les trois graines donnent des exactitudes de 0,431, 0,402 et 0,391 à la sévérité maximale, amplitude bien trop faible pour attribuer ce comportement au hasard de l’initialisation.

Le mécanisme de cette défaillance est identifiable. La vacuité est bornée par la quantité d’évidence que le calendrier de pénalisation a appris au réseau à émettre. Sur des images bruitées, la fonction softmax continue de produire une évidence non négligeable pour l’une des classes, si bien que la vacuité ne peut pas atteindre les valeurs élevées attendues. Le modèle devient donc confiant et faux, avec un plafond d’incertitude trop bas, ce qui constitue l’inverse exact du comportement recherché.

Le même diagnostic apparaît sur le jeu synthétique, où l’incertitude de l’Evidential Deep Learning ne progresse que de 0,617 à 0,685 alors que celle des Deep Ensembles passe de 0,476 à 0,983. La reproductibilité de ce comportement sur deux jeux de données indépendants et sur trois graines renforce l’hypothèse d’une limitation intrinsèque à la formulation employée plutôt que d’un artefact expérimental.




FIGURE 3 – Exactitude, incertitude moyenne et ECE en fonction de la sévérité du bruit gaussien. Le comportement souhaitable associe une exactitude décroissante à une incertitude croissante.

5.8 Coût de calcul

Le tableau 5 rappelle le coût de chaque stratégie, exprimé en multiples de l’entraînement et de l’inférence de la référence.

TABLE 5 – Coût relatif des méthodes. Les temps mesurés correspondent à l’inférence complète sur les 624 images de test, sur processeur.

Méthode	Entraînement	Inférence	Temps mesuré
Référence softmax	1×	1 <i>forward pass</i>	environ 2 s
Temperature scaling	1×	1 <i>forward pass</i>	environ 2 s
Evidential Deep Learning	1×	1 <i>forward pass</i>	environ 2 s
Deep Ensemble ($M = 5$)	5×	5 <i>forward passes</i>	environ 6 s
MC Dropout ($S = 30$)	1×	30 <i>forward passes</i>	environ 35 s

Rapporté à la calibration obtenue, ce tableau constitue l’argument central du travail, illustré par la figure 4. L’Evidential Deep Learning occupe la position la plus favorable du plan coût contre calibration, en obtenant le meilleur ECE au coût minimal. Les Deep Ensembles achètent la meilleure qualité de décision et la meilleure reproductibilité au prix de cinq entraînements complets, ce qui reste acceptable pour un modèle de cette taille mais devient prohibitif pour une architecture volumineuse. Le MC Dropout occupe la position la moins favorable en distribution, avec un coût d’inférence trente fois supérieur pour un gain de calibration modeste et un AUC dégradé, mais devient l’option la plus intéressante lorsque la robustesse au décalage prime et que le budget d’entraînement est limité à un seul réseau.




FIGURE 4 – Calibration en fonction du coût de calcul, en échelle logarithmique. La position idéale se situe en bas à gauche.

Note sur la construction des cartes. Un réseau de segmentation attribue une probabilité à chaque pixel, si bien que la carte d’incertitude existe naturellement. Le classifieur étudié ici ne produit qu’une seule sortie pour l’image entière. Il annonce par exemple une pneumonie avec une incertitude de 0,17, sans indiquer à quel endroit de la radiographie se situe son hésitation. Pour obtenir une information spatiale, il faut donc modifier l’image et observer comment le modèle réagit.

La procédure est la suivante. Un carré de huit pixels de côté est placé dans le coin supérieur gauche de l’image. Les pixels qu’il recouvre sont remplacés par une valeur unique, la moyenne de toute l’image, ce qui transforme la zone en une plage neutre dépourvue de structure anatomique. L’image modifiée traverse ensuite la chaîne complète de quantification et l’incertitude obtenue est enregistrée. Le carré est décalé de quatre pixels vers la droite et l’opération recommence, ligne après ligne, jusqu’à couvrir toute l’image. En soustrayant l’incertitude mesurée sur l’image intacte, on obtient la carte présentée.

Le choix de la valeur moyenne mérite d’être justifié. Remplacer la zone par du noir créerait une structure artificielle, car un carré sombre ressemble à une opacité que le réseau pourrait interpréter comme un signe pathologique. On mesurerait alors sa réaction à un faux signal ajouté plutôt qu’à une information retirée. La valeur moyenne ne ressemble ni à une structure dense ni à une zone aérée, et se rapproche donc de l’idée d’une absence d’information.

La lecture est simple. Lorsque le masquage d’une région fait monter l’incertitude, c’est que cette région portait l’évidence sur laquelle reposait la décision, et la carte l’affiche en rouge. Lorsque le masquage la fait baisser, c’est que la région contenait un signal contradictoire dont la disparition simplifie la décision, et la carte l’affiche en bleu.

Cette approche a un coût élevé. Chaque carte demande environ vingt cinq positions de carré, chacune exigeant une évaluation complète du modèle. Pour le MC Dropout, cela représente vingt cinq fois trente *forward passes*, soit sept cent cinquante traversées du réseau pour une seule image, ce qui explique que la génération des cartes demande environ cinquante secondes pour cette méthode contre cinq secondes pour l’Evidential Deep Learning.

6 Discussion

6.1 Aucune méthode n'est uniformément supérieure

Le résultat le plus solide de ce travail est négatif au sens où il interdit une recommandation unique. Le classement des méthodes dépend entièrement du régime considéré.

En distribution, l'Evidential Deep Learning offre la meilleure calibration au coût minimal, et les Deep Ensembles la meilleure qualité de décision. Hors distribution, ce classement s'inverse : le MC Dropout devient la méthode la plus robuste, et l'Evidential Deep Learning devient la moins fiable.

Cette dépendance au régime a une conséquence pratique immédiate. Le choix d'une méthode de quantification d'incertitude ne peut pas se fonder sur une comparaison menée uniquement sur des données propres, car cette comparaison n'informe pas sur le comportement en conditions de déploiement.

Le contrôle sur le jeu synthétique éclaire ce point. Sur ces données, où les erreurs sont aléatoires par construction et où aucun décalage n'existe entre validation et test, la référence softmax obtient le meilleur ECE, avec 0,0242 contre 0,0356 pour l'Evidential Deep Learning. Autrement dit, lorsqu'il n'existe aucune ignorance à mesurer, la machinerie épistémique n'apporte rien et peut même dégrader légèrement le résultat. L'écart observé sur PneumoniaMNIST provient donc bien du décalage réel entre patients d'entraînement et patients de test.

6.2 Le MC Dropout ne remplace pas l'ensembling

En distribution, le MC Dropout coûte trente fois l'inférence de la référence pour un gain de calibration limité et une prédiction sélective légèrement inférieure. Cette observation ne tient pas au coût mais à un fait plus profond : le bruit de dropout approxime une postérieure sur des poids qu'un réseau entraîné par entropie croisée n'a jamais réellement élargie au delà des données observées.

Les Deep Ensembles tirent leur diversité de trajectoires d'optimisation véritablement distinctes, et l'Evidential Deep Learning la tire d'un objectif explicitement entraîné à signaler l'absence d'évidence. Ce sont des avantages structurels qu'aucune quantité d'échantillonnage ne reconstitue.

Le MC Dropout conserve néanmoins une place légitime. Il s'applique en une ligne de code à un modèle déjà entraîné, sans coût d'entraînement additionnel, et s'est révélé le plus robuste sous dégradation. Il constitue donc un premier recours raisonnable, mais non un substitut à l'ensembling lorsque les ressources le permettent.

6.3 Un artefact d'implémentation instructif

Une première série de résultats comportait une anomalie détectée par un contrôle de cohérence élémentaire. La référence et sa version corrigée par temperature scaling affichaient des exactitudes différentes, 0,8478 contre 0,8349. Or le temperature scaling est une transformation strictement monotone des logits, incapable par construction de modifier la classe prédite. Les deux valeurs devaient donc être identiques.

L'origine était la suivante. Les prédicteurs partageaient le même objet réseau en mémoire, et le prédicteur MC Dropout remplaçait les couches de dropout en mode stochastique sans jamais les restaurer. L'évaluation suivant l'ordre du dictionnaire, la configuration évaluée après le MC Dropout héritait d'un dropout resté actif et produisait des prédictions stochastiques.

La correction a consisté à réaffirmer le mode déterministe à chaque lot plutôt qu'une seule fois à la construction, et un test de non régression a été ajouté. Cet épisode illustre un point de méthode qui dépasse le cas particulier : les erreurs les plus dangereuses ne provoquent pas d'exception, elles produisent des nombres plausibles. Seule une invariance connue a priori, ici l'égalité obligatoire de deux exactitudes, permet de les détecter.

6.4 Limites

Plusieurs limites doivent être énoncées.

La résolution de 28×28 propre à MedMNIST reste très éloignée des images cliniques réelles. Le classement relatif des configurations se transporte vraisemblablement, mais les valeurs absolues d'ECE sur des images en pleine résolution seront différentes.

Trois graines constituent un progrès sur l'exécution unique, mais demeurent un effectif faible pour estimer un écart type. Les intervalles rapportés doivent être lus comme des ordres de grandeur plutôt que comme des bornes rigoureuses, et un protocole plus exigeant en emploierait dix. Cette réserve ne remet toutefois pas en cause les conclusions retenues, qui reposent toutes sur des effets observés de façon identique sur les trois répétitions.

La répétition a par ailleurs conduit à écarter une comparaison que l'exécution initiale semblait autoriser. Les écarts d'AUC de détection d'erreur entre configurations, de l'ordre de 0,009, se sont révélés inférieurs à l'écart type entre graines, de l'ordre de 0,017. Aucun classement des configurations sur cette métrique n'est donc défendable à partir de ces données, et il est vraisemblable qu'une part de la littérature comparative sur des jeux de test de quelques centaines d'images se heurte à la même difficulté sans toujours l'explicitier.

Les cartes par occlusion répondent à la question de savoir quelle région porte l'évidence, et non à celle de savoir quel pixel est incertain. Seul un modèle de segmentation fournit directement la seconde réponse.

Enfin, les dégradations employées demeurent synthétiques. Un décalage réel entre appareils, protocoles d'acquisition et populations est plus difficile à caractériser et probablement plus sévère qu'un bruit gaussien additif.

7 Conclusion et perspectives

Ce travail a implémenté et comparé cinq configurations de quantification d'incertitude pour la classification d'images médicales, en mettant l'accent non sur la production d'une incertitude mais sur la vérification de sa fiabilité, et en répétant l'intégralité du protocole sur trois graines.

Sur données propres, l'Evidential Deep Learning obtient la meilleure calibration pour le coût d'un unique *forward pass*, avec une réduction de 51 % de l'ECE par rapport à la référence, avantage confirmé sur chacune des trois répétitions. Les Deep Ensembles obtiennent la meilleure qualité de décision au prix de cinq entraînements, et apportent surtout une reproductibilité que les autres configurations n'atteignent pas, leur variabilité entre graines étant inférieure d'un facteur dix à celle de la référence. Sous décalage de distribution, le MC Dropout se révèle le plus robuste alors que l'Evidential Deep Learning se dégrade fortement, comportement reproduit sur deux jeux de données indépendants et sur trois graines. Le temperature scaling échoue systématiquement lorsque validation et test ne partagent pas la même distribution, situation qui constitue précisément le cas clinique nominal.

La recommandation pratique dépend donc du contexte de déploiement. Dans un environnement étroitement contrôlé, où les données de production ressemblent aux données d'entraînement, la référence softmax accompagnée d'un temperature scaling validé sur des données réellement représentatives suffit. Dans un environnement ouvert, où l'apparition de données hors distribution est probable, les Deep Ensembles constituent le choix le plus sûr lorsque le budget d'entraînement le permet, la stabilité de leurs résultats étant un argument aussi important que leur performance moyenne. Le MC Dropout offre une solution de repli applicable à un modèle existant, sans coût d'entraînement additionnel, et se révèle le plus résistant à la dégradation des images. L'Evidential Deep Learning offre le meilleur rapport entre calibration et coût, mais sa fragilité hors distribution interdit de le déployer sans un mécanisme complémentaire de détection.

Un enseignement de méthode se dégage enfin de la répétition du protocole. Sur un jeu de test de quelques centaines d'images, la variance d'initialisation atteint le même ordre de grandeur que les écarts entre méthodes. Une comparaison menée sur une exécution unique risque donc de

rapporter comme un effet ce qui n'est qu'un tirage favorable, et la répétition devrait constituer la norme plutôt que l'exception dans ce domaine.

Plusieurs prolongements se dégagent. Le premier consiste à étudier le calendrier de pénalisation de l'Evidential Deep Learning, dont le plafond de vacuité semble constituer la cause directe de sa fragilité : une pénalisation plus forte et plus précoce devrait élargir la plage de vacuité accessible, probablement au prix d'une légère perte d'exactitude. Le deuxième consiste à transposer l'étude à une tâche de segmentation, où l'incertitude par pixel est directement disponible et où l'analyse spatiale ne nécessite plus d'occlusion. Le troisième consiste à valider les conclusions sur des images en pleine résolution et sur un décalage inter sites authentique plutôt que simulé. Le quatrième consiste à évaluer des ensembles de taille réduite, à deux ou trois membres, afin de déterminer si le bénéfice de reproductibilité observé apparaît dès les premiers membres ou requiert l'effectif complet.

Références

- [1] Y. Gal et Z. Ghahramani. Dropout as a Bayesian Approximation : Representing Model Uncertainty in Deep Learning. *International Conference on Machine Learning*, 2016.
- [2] B. Lakshminarayanan, A. Pritzel et C. Blundell. Simple and Scalable Predictive Uncertainty Estimation using Deep Ensembles. *Advances in Neural Information Processing Systems*, 2017.
- [3] M. Sensoy, L. Kaplan et M. Kandemir. Evidential Deep Learning to Quantify Classification Uncertainty. *Advances in Neural Information Processing Systems*, 2018.
- [4] C. Guo, G. Pleiss, Y. Sun et K. Q. Weinberger. On Calibration of Modern Neural Networks. *International Conference on Machine Learning*, 2017.
- [5] Y. Ovadia et al. Can You Trust Your Model's Uncertainty? Evaluating Predictive Uncertainty Under Dataset Shift. *Advances in Neural Information Processing Systems*, 2019.
- [6] A. Kendall et Y. Gal. What Uncertainties Do We Need in Bayesian Deep Learning for Computer Vision *Advances in Neural Information Processing Systems*, 2017.
- [7] J. Yang et al. MedMNIST v2 : A Large Scale Lightweight Benchmark for 2D and 3D Biomedical Image Classification. *Scientific Data*, volume 10, 2023.

ing. François Lachance Awounang-Ngounou

« Le danger n'est pas que la machine ignore.
C'est qu'elle ignore qu'elle ignore,
et que nous ayons cessé de le vérifier. »